

# Tema de casa nr 5 mspi

Dimitriu Gabriel ISC

15.06.2000

## 1 Prezentarea succinta a metodele statistice utilizate

### 1.1 Inferenta asupra mediei

In acest proiect se foloseste numai inferentele de medie pentru  $\sigma^2$  necunoscut deoarece nu cunoastem dispersia, ea urmind sa fie evaluata la un moment ulterior, dar folosim si estimarea si testul de medie.

#### 1.1.1 Estimare

Acesta inferenta vrea sa determine media dintr-un esantion de date i.i.d. de volum  $N$  date  $[x_1, x_2, \dots, x_N]$  rezultind  $\bar{x}$  estimatia care este de distributie gaussiana  $\bar{X} = N(\mu, \sigma^2/N)$ .

Se construiesc

$$T = \sqrt{N} \frac{\bar{X} - \mu}{S}$$

unde  $S$  este un estimator al dispersiei:

$$S = \frac{1}{N-1} \sum_{i=1}^N (X_i - \bar{X})^2$$

Sau pentru estimatie avem:

$$t = \sqrt{N} \frac{\bar{x} - \mu}{s}$$

cu

$$s = \frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})^2$$

Se demonstreaza ca  $T$  are legea de repartitie Student cu  $N-1$  grade de libertate daca variabila aleatoare  $X$  masurata este Gaussiana. De observat ca pentru  $N > 30$  legea Student se comporta ca o lege Gauss.

Se spune ca  $P(|T| < t_{\alpha/2}) = 1 - \alpha \Rightarrow |t| < t_{\alpha/2}$  in  $(1 - \alpha) * 100\%$  din cazuri.

Deci

$$\left\| \sqrt{N} \frac{\bar{x} - \mu}{s} \right\| < t_{\alpha/2}$$

Iar intervalul de incredere este

$$[\bar{x} - \varepsilon, \bar{x} + \varepsilon]$$

cu  $\varepsilon = t_{\alpha/2} \frac{s}{\sqrt{N}}$

Daca nu se specifica N trebuie sa se faca iteratii pentru aflarea lui.

### 1.1.2 Testare

Se presupune ca datele de intrare provin din populatii gaussiene deci  $[x_1, x_2, \dots, x_N] \in N(\mu, \sigma^2)$  si sunt i.i.d.

Se pun ipotezele  $H_0 : \mu = \mu_0$  si  $H_1 : \mu \neq \mu_0$ .

Se alege  $\alpha$  care este pragul de semnificatie, calculez  $t = \sqrt{N} \frac{\bar{x} - \mu_0}{s}$  care are adistributia Student.

Accept testul dacat  $t \in (-t_{\alpha/2}, t_{\alpha/2})$ , adica ipoteza  $H_0$  si daca  $t \notin (-t_{\alpha/2}, t_{\alpha/2})$  accept ipoteza  $H_1$ .

Eroare de ordin I este  $\alpha$  iar eroarea de ordin II este  $\beta$ .

## 1.2 Inferente asupra dispersiei

In acest caz se va folosi inferetele asupra dispersiei dar cu media necunoscute. Caz in care se restring ipotezele la populatii gaussiene.

### 1.2.1 Estimare

Avem datele  $[x_1, x_2, \dots, x_N]$  de distributie  $X \sim N(\mu, \sigma^2)$

Trebuie cunoscuta legea de distributie a variabilelor de intrare deoarece dispersia dispersiei este dependenta de tipul populatiei astfel ca estimatiile sunt:

$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$$

$$s^2 = \frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})^2$$

Iar pentru populatii gaussiene avem:

$$(N-1)s^2 = \sum_{i=1}^N (x_i - \bar{x})^2$$

Atentie acesta suma de patrute de distributii gauss nu sunt independente intre ele, deoarece au aceasi medie  $\bar{x}$ . Deci nu se poate supe direct ca este legea  $\chi^2$  de N grade de libertate. Se poate demonstra ca acesta este o lege de tip  $\chi^2$  de N-1 grade de libertate si de parametru  $\sigma^2$ .

Avem:

$$(N-1) \frac{S^2}{\sigma^2} = Y = \chi_{N-1;1}^2 \in (y_{1-\alpha/2}, y_{\alpha/2})$$

valabila cu probabilitatea  $1 - \alpha$ .

Aleg  $1 - \alpha$  N este dat si voi determina  $y_{\alpha/2}$  si  $y_{1-\alpha/2}$ .

Dupa prelucrari avem:

$$\sigma^2 \in \left( \frac{(N-1) * s^2}{y_{\alpha/2}}, \frac{(N-1) * s^2}{y_{1-\alpha/2}} \right)$$

In care avem erorile:

$$\varepsilon_- = \frac{(N-1) * s^2}{y_{\alpha/2}}$$

$$\varepsilon_+ = \frac{(N-1) * s^2}{y_{1-\alpha/2}}$$

Daca  $N > 800$  functia  $\chi^2$  se simetrizeaza si  $\varepsilon_- = \varepsilon_+$ .

### 1.2.2 Testare

Se foloseste aceleasi ipoteze statistice ca si pentru estimare.

Ipoteze de test:  $H_0 : \sigma^2 = \sigma_0^2$  si  $H_1 : \sigma^2 \neq \sigma_0^2$ . Se alege  $\alpha$  si se calculeaza

$$y_{calc} = \frac{(N-1) * s^2}{\sigma_0^2}$$

Daca  $y_{calc} \in$  zona de acceptare se trece testul daca nu se resping datele.

## 1.3 Testul de concordanta Kolmogorov Smirnov

Este un test de concordanta mai puternic decat testul  $\chi^2$  si se foloseste numai pentru legi de repartitie continue. Este un test neparametric (liber de repartitie).

Ca variabile de intrare avem N observatii i.i.d.  $[x_1, x_2, \dots, x_N]$  ordonate crescator:  $x_1 \leq x_2 \leq \dots \leq x_N$ .

Concordanta se face cu o lege continua specificata  $F(x)$  de parametri cunoscuti sau necunoscuti.

Formulam ipotezele statistice:

$H_0$ : legea de repartitie este  $F(x)$

$H_1$ : legea de repartitie nu este  $F(x)$

Se alege pragul  $\alpha$  de semnificatie statistica.

Se calculeaza functia de repartitie empirica.

$$F_N(x) = P\{X \leq x\} = \frac{m_x}{N}$$

$F_N(x)$  este o curba in trepte care se suprapune peste curba teoretica si se calculeaza:

$$\Delta = \max_{-\infty < x < \infty} |F(x) - F_N(x)|$$

$$P\{\Delta < \Delta_\alpha\} = P\{\sqrt{N}\Delta < \sqrt{N}\Delta_\alpha\} = 1 - \alpha$$

Pentru  $N > 80$  avem

$$\Delta_\alpha \simeq \sqrt{\frac{1}{2N} \ln \frac{2}{\alpha}}$$

Din datele experimentale evaluam

$$\Delta = \sup_{-\infty < x < \infty} |F(x) - F_N(x)|$$

Daca  $\Delta < \Delta_\alpha$  acceptam  $H_0$ .

Daca  $\Delta > \Delta_\alpha$  respingem datele ca fiind semnificative.

Zona de acceptare test este  $(0, \Delta_\alpha)$ .

Zona de respingere test este  $(\Delta_\alpha, 0)$ .

## 2 Prezentarea metodei propuse

Intii vom face o estimare de medie asupra generatorului de numere aleatoare cu insumarea a  $N$  secvente uniforme. Cu valoarea estimata vom face un test de medie asupra generatorului preimplementat astfel incit se va observa daca mediile difera. Se mai putea face si cu o diferenta de medie pe baza a doua multimi de date experimentale.

Apoi vom face o estimare de dispersie asupra generatorului de numere aleatoare cu insumarea a  $N$  secvente uniforme. Cu valoarea estimata vom face un test de dispersie asupra generatorului preimplementat astfel incit se va observa daca dispersiile acestora difera. Se mai putea face si cu o diferenta de dispersie pe baza a doua multimi de date experimentale.

In final se va face un test Kolmogorov-Smirnov pentru a vedea daca generatorul de numere aleatoare cu insumarea a  $N$  secvente uniforme este un generator aleator gaussian ca forma.

## 3 Concluzii

Generatorul de date aleatoare obtinut prin insumare este identic cu increderea 95.0% daca se ia  $N=5-6$ . De exemplu cu  $N=3$  nu este trecut testul de dispersie.